





Bio-Sentry Système

**Pharmacovigilance et Veille
Épidémiologique**

Présenté par

**Oumaima Enajjari
Khouloud El Hajji
Aya Chakour
Amal Afenich**





Introduction


Comprendre le contexte de Bio-Sentry

L'évolution du numérique a entraîné une croissance importante des données de santé disponibles sur le web. Les patients partagent de plus en plus leurs expériences médicales sur les forums, plateformes spécialisées et réseaux sociaux. Ces données représentent une source précieuse pour la surveillance sanitaire et la pharmacovigilance.

Toutefois, leur volume et leur nature non structurée rendent leur exploitation difficile avec les approches classiques.

Le projet Bio-Sentry vise à exploiter les techniques de Web Mining et d'analyse intelligente pour transformer ces données en informations exploitables.





Introduction

Problématique

- Les méthodes traditionnelles de pharmacovigilance reposent principalement sur des déclarations officielles souvent tardives.
- Les signaux faibles liés aux effets indésirables peuvent apparaître plus tôt sur le web à travers les témoignages des utilisateurs.
- Cependant, ces données sont :
 - massives,
 - textuelles,
 - hétérogènes,
 - parfois subjectives.

Comment concevoir un système capable de collecter, analyser et détecter automatiquement des signaux de risque médicamenteux à partir des données du web ?






RxNorm — Référentiel des Médicaments




Ce que RxNorm fournit :

- Identifiants uniques (RxCUI) par médicament
- Normalisation des noms commerciaux ↔ noms génériques
- Synonymes et variantes orthographiques
- Classes thérapeutiques standardisées



Architecture Générale du Système





Collecte des Données

Source	Type de données	Nombre de données collectées	Outil de scraping utilisé	Pourquoi cet outil ?
ClinicalTrials	Essais cliniques, traitements, effets secondaires	382 documents	Requests + BeautifulSoup	Structure HTML stable et extraction rapide des données publiques
PubMed	Articles scientifiques biomédicaux	1 601 articles	Entrez API (BioPython)	API officielle adaptée à l'extraction d'articles scientifiques structurés
OpenFDA (FAERS)	Rapports officiels de pharmacovigilance	7 000 rapports	OpenFDA API	Fournit directement des données JSON structurées et fiables
MedlinePlus	Informations médicales et effets secondaires	1 979 médicaments	Selenium + BeautifulSoup	Certaines sections sont dynamiques et nécessitent le rendu JavaScript
WebMD	Effets secondaires et descriptions médicales	371 pages	Selenium	siite dynamique avec chargement JavaScript : nécessite une navigation réelle
Drugs.com	Témoignages patients et effets secondaires	4 819 avis	Requests + BeautifulSoup	Structure HTML stable et extraction rapide des données publiques
Reddit	Publications communautaires et commentaires	2 161 posts/commentaires	Requests + endpoints JSON publics	Endpoints JSON accessibles sans authentification, ciblant des subreddits médicaux spécialisés



Stockage Big Data

Architecture Hybride NoSQL:

MongoDB Atlas

- Schéma flexible:
- Scalabilité horizontale
- Intégration Python
- 4 collections :
 - raw_sources
 - normalised_sources
 - enriched_signals
 - temporal_signals

Neo4j

- Graphe de citations
- Nœuds : sources
- Relations : :CITE
- Calcul scores HITS
- sources Scores réinjectés dans MongoDB



Extraction Sémantique Biomédicale



Modèle : BioBERT (Transformer biomédical)+scibert(fine-tuning médical)

3 tâches principales :

1. NER — Reconnaissance d'entités → Médicaments · Symptômes · Maladies · Posologies

2. Classification de relations → Effet secondaire (médicament → effet) → Symptôme (maladie → manifestation) Méthode : embeddings BioBERT + régression logistique


3. Normalisation terminologique → Standard : MedDRA → "mal de tête" = "céphalée" = "headache"

Output : side_effects · symptoms · dosages





Score de Fiabilité des Sources



Les sources d'information médicale n'ont pas toutes le même niveau de fiabilité. Par exemple, une publication scientifique sur PubMed est beaucoup plus fiable qu'un contenu provenant de plateformes communautaires comme Reddit.


Bio-Sentry modélise les relations de citation entre sources sous forme de graphe, puis applique l'algorithme HITS (Hyperlink-Induced Topic Search) pour calculer un score de fiabilité.

Principe algorithmique :

- **Authority** : une source est fiable si elle est fortement citée par d'autres sources
- **Hub** : une source est fiable si elle référence des sources de qualité



Score de Fiabilité des Sources



HITS – Scores de confiance des sources

Source	Type	Authority	Hub	Dist
PubMed	authority	1.0000	0.0000	0
ClinicalTrials.gov	authority	0.8880	0.3035	0
OpenFDA (FAERS)	authority	0.8573	0.5730	0
MedlinePlus	authority	0.5498	0.8331	0
WebMD	hub	0.2069	1.0000	1
Drugs.com	hub	0.0261	0.4898	1
Reddit	hub	0.0000	0.0707	2

Après itérations et convergence, les sources sont classées selon leur niveau de fiabilité, de PubMed (plus fiable) à Reddit (moins fiable).



Détection d'Anomalies

Algorithme	Définition	Pourquoi utilisé ?	Anomalies détectées	Taux
LOF (Local Outlier Factor)	Algorithme non supervisé basé sur la densité locale des points par rapport à leurs voisins.	Adapté aux données déséquilibrées et capable de détecter des ruptures locales de densité dans les signaux de pharmacovigilance.	372	1.9%
Isolation Forest	Méthode basée sur des arbres aléatoires qui isole rapidement les points atypiques dans l'espace des données.	Efficace pour les données multidimensionnelles et les grands volumes de données médicales.	495	2.5%
Z-Score Rolling	Méthode statistique temporelle comparant chaque valeur à une moyenne glissante locale.	Permet de détecter des pics temporels inhabituels dans l'évolution des effets secondaires.	252	1.3%



Détection d'Anomalies

Niveau d'alerte	Consensus	Nombre de documents	Pourcentage	Interprétation
● NORMAL	0/3 algorithmes	18 972	95.0%	Aucun signal anormal détecté
● MODÉRÉ	1/3 algorithmes	885	4.4%	Signal faible détecté par un seul modèle
● ÉLEVÉ	2/3 algorithmes	117	0.6%	Alertes prioritaires nécessitant une analyse approfondie
● CRITIQUE	3/3 algorithmes	0	0.0%	Aucun consensus total détecté

Ce tableau présente un système de consensus : plus le nombre d'algorithmes détectant une même anomalie est élevé, plus le niveau d'alerte est critique. Un signal confirmé par 3 modèles différents est considéré comme une certitude, tandis qu'un signal détecté par un seul modèle reste à surveiller.



Clustering des Profils de Risque



3 Algorithmes — 3 Paradigmes

Algorithme	Clusters	Silhouette
K-Means	4	0.32
Agglomerative (Ward)	4	0.55 ✓
HDBSCAN	3	0.31



L'algorithme Agglomerative (Ward) présente le meilleur score de silhouette (0.55), indiquant une séparation plus cohérente et plus homogène des profils de risque par rapport à K-Means et HDBSCAN. Il a donc été retenu comme modèle de clustering le plus performant pour cette analyse.





Éthique & Conformité



- ✓ RGPD : aucune donnée personnelle identifiable stockée
- ✓ Anonymisation des contenus communautaires
- ✓ Respect des politiques robots.txt
- ✓ Finalité strictement académique
- ⚠ Bio-Sentry = outil d'aide à la décision Pas un système de diagnostic autonome

Dashboard de visualisation