



UNIVERSITÉ ABDELMALEK ESSAÂDI

École Nationale des Sciences Appliquées — Tétouan

Filière : Sciences des Données, Big Data & Intelligence Artificielle

Module : Analyse de Web

RAPPORT DE PROJET

Bio-Sentry

Système de Détection Précoce des Effets Secondaires Médicamenteux

Pharmacovigilance et Veille Épidémiologique

Réalisé par :

Aya Chakour

Amal Afenich

Oumaima Enajjari

Khouloud El Hajji

Encadré par :

Prof. Imad Sassi

Année Universitaire : 2025-2026

Résumé

Le projet **Bio-Sentry** propose un système intelligent de veille épidémiologique et de pharmacovigilance basé sur les techniques de Web Mining, de Big Data et d'Intelligence Artificielle. L'objectif principal du système est de collecter, centraliser et analyser automatiquement des données hétérogènes issues du web afin d'identifier des effets indésirables potentiellement émergents avant les alertes sanitaires officielles.

Le projet repose sur trois axes fondamentaux du *Web Mining* : le *Web Content Mining*, le *Web Structure Mining* et le *Web Usage Mining*. Dans le cadre de ce travail, une attention particulière a été portée à l'axe du *Web Usage Mining*, qui vise l'analyse comportementale et temporelle des données afin de détecter des anomalies, des signaux de pharmacovigilance ainsi que des regroupements comportementaux significatifs.

Pour atteindre ces objectifs, plusieurs approches de *Machine Learning* non supervisé ont été étudiées et comparées, notamment **HDBSCAN**, **Isolation Forest**, **Local Outlier Factor (LOF)**, **K-Means** et le **Clustering Agglomératif**. Différentes méthodes statistiques ont également été utilisées, telles que le **Rolling Z-Score** et l'**IQR de Tukey**. Des techniques de clustering ont ensuite été appliquées afin d'identifier automatiquement des groupes d'effets secondaires similaires et de mettre en évidence des comportements atypiques ou rares.

Le système développé s'appuie sur une architecture *Big Data* utilisant **MongoDB** pour le stockage et la gestion des données massives et hétérogènes collectées depuis différentes sources web. Une phase importante de prétraitement et d'analyse de qualité des données a également été intégrée afin d'assurer la cohérence, la fiabilité et la pertinence des résultats obtenus.

Les résultats obtenus démontrent l'intérêt des approches de *Web Mining* et d'apprentissage non supervisé dans le domaine de la pharmacovigilance numérique. Le projet met en évidence la capacité des modèles utilisés à détecter automatiquement des comportements anormaux et des signaux faibles susceptibles d'indiquer des effets secondaires émergents, ouvrant ainsi la voie à des systèmes de surveillance médicale plus réactifs et intelligents.

Table des matières

1	Contexte et Objectifs du Projet	4
1.1	Contexte et Problématique	4
1.2	Objectifs	4
2	Architecture Générale du Système	4
3	Stockage Big Data	5
3.1	MongoDB Atlas	5
3.1.1	Présentation	5
3.1.2	Justification du choix	5
3.2	Neo4j — Graphe de Citations HITS	5
4	Collecte et Extraction des Données	6
4.1	Choix des Sources	6
4.2	Construction de la Référence Médicamenteuse (RxNorm)	6
4.3	Extraction par Source	7
4.3.1	MedlinePlus	8
4.3.2	OpenFDA	9
4.3.3	Drugs.com	9
4.3.4	PubMed	10
4.3.5	ClinicalTrials	10
4.3.6	Reddit	11
4.3.7	WebMD	11
5	Axe 1 : Web Content Mining & NLP Biomédical	12
6	Axe 2 : Score de Fiabilité des Sources (HITS)	13
6.1	Pourquoi noter les sources ?	13
6.2	L'algorithme HITS	14
6.3	Résultats	14
6.4	Modélisation du Graphe (Neo4j)	14
7	Pipeline de Normalisation et Enrichissement	15
7.1	Chargement des Scores HITS	15
7.2	Normalisation par Source	16
7.3	Classification NLP	16
7.4	Filtrage des Documents Non Informatifs	16
7.5	Déduplication et Stockage	16
7.6	Normalisation Temporelle des Signaux	16
7.7	Contrôle Qualité des Données	16
8	Axe 3 : Web Usage Mining — Surveillance Épidémiologique	17
8.1	Objectif	17
8.2	Données utilisées	18
8.2.1	Nettoyage et Biais	18
8.2.2	Distribution temporelle finale	18
8.3	Détection d'Anomalies — 3 Algorithmes Comparés	18
8.3.1	Local Outlier Factor (LOF)	18

8.3.2	Isolation Forest	19
8.3.3	Z-Score Rolling	19
8.3.4	Comparaison et Consensus des 3 Algorithmes	20
8.3.5	Justification du choix des 3 algorithmes	21
8.4	Clustering — 3 Algorithmes Comparés	22
8.4.1	K-Means	22
8.4.2	Agglomerative Clustering	23
8.4.3	HDBSCAN	23
8.4.4	Comparaison des 3 Algorithmes	24
8.4.5	Justification du choix des 3 algorithmes de clustering	25
9	Dashboard Interactif	25
9.1	Vue d'Ensemble	25
9.2	Exploration de Contenu	27
9.3	Exploration de Structure	27
9.4	Heatmap des Co-occurrences	28
9.5	Recherche de Médicaments	29
9.6	Détection d'Anomalies	30
9.7	Clustering des Signaux	31
9.8	Qualité des Données	32
10	Éthique et Conformité RGPD	33
10.1	Respect du RGPD	33
10.2	Respect des politiques robots.txt	33
10.3	Fiabilité et biais des données	33
10.4	Usage responsable de l'Intelligence Artificielle	34
10.5	Limites éthiques du système	34
11	Recommandations pour les professionnels de santé	34
11.1	Renforcement de la veille pharmacovigilante	34
11.2	Priorisation des signaux critiques	34
11.3	Surveillance des tendances temporelles	34
11.4	Exploitation des données communautaires	35
11.5	Amélioration continue des modèles IA	35
11.6	Collaboration entre experts médicaux et data scientists	35
11.7	Perspectives futures	35

1 Contexte et Objectifs du Projet

1.1 Contexte et Problématique

Face à la multiplication des traitements complexes, la pharmacovigilance traditionnelle peine à identifier rapidement les effets indésirables rares ou émergents signalés par les patients sur le web. Les canaux officiels (FAERS, VigAccess) présentent des délais de reporting pouvant atteindre plusieurs mois, créant une fenêtre d'exposition non surveillée pour les patients.

Le projet **Bio-Sentry** s'inscrit dans ce contexte en exploitant le *Web Mining* pour collecter et analyser massivement des données issues de plateformes médicales officielles, de bases de pharmacovigilance et d'avis patients en ligne. La problématique centrale réside dans la capacité du système à traiter des données textuelles non structurées et souvent subjectives afin d'en extraire des **signaux faibles de toxicité**, permettant ainsi une **détection précoce et automatisée** des risques médicamenteux avant même les alertes sanitaires officielles.

1.2 Objectifs

- Concevoir un système automatisé croisant données officielles, publications scientifiques et témoignages patients.
- Identifier des effets secondaires potentiels non encore répertoriés.
- Quantifier la fiabilité des sources par algorithme de graphe.
- Normaliser temporellement les signaux pour détecter des émergences.
- Produire une base de données hybride exploitable pour la veille épidémiologique.

2 Architecture Générale du Système

La figure 1 présente le pipeline global de Bio-Sentry, depuis la récupération des listes de médicaments jusqu'à la visualisation des résultats.




FIGURE 1 – Architecture générale du pipeline Bio-Sentry

Bio-Sentry suit un pipeline entièrement automatisé en six étapes successives. Une liste de médicaments issue de **RxNorm** alimente **sept scrapers** qui collectent les données depuis des sources hétérogènes (forums, bases cliniques, réseaux sociaux médicaux). L'algorithme **HITS** (*Hyperlink-Induced Topic Search*) évalue ensuite la fiabilité de chaque source en calculant un score d'autorité, permettant de pondérer les signaux selon leur crédibilité.

Un pipeline **NLP** basé sur **BioBERT** extrait automatiquement les entités biomédicales (médicaments, effets indésirables, relations) depuis les textes bruts collectés. Les données sont ensuite normalisées et consolidées dans la collection `enriched_signals`, constituant la base unifiée du système. Enfin, les algorithmes de **Machine Learning** — détection d'anomalies et clustering — identifient les signaux prioritaires et les profils de risque `drug + side_effect` à surveiller.

3 Stockage Big Data

3.1 MongoDB Atlas

3.1.1 Présentation

MongoDB Atlas est une base de données NoSQL orientée documents hébergée dans le cloud. Chaque document est stocké au format BSON (Binary JSON), ce qui permet de représenter nativement des structures hétérogènes sans schéma fixe.

3.1.2 Justification du choix

- **Flexibilité du schéma** : Les données issues de sources variées (OpenFDA, Reddit, Drugs.com...) ont des structures très différentes. MongoDB accepte ces documents sans migration de schéma.
- **Scalabilité horizontale** : Le sharding natif permet de répartir les données sur plusieurs nœuds pour absorber des volumes croissants.
- **Intégration Python** : La bibliothèque PyMongo offre une API fluide pour les opérations CRUD et les pipelines d'agrégation.
- **Atlas Search** : Indexation full-text intégrée, utile pour interroger les textes bruts des avis patients.
- **Hosting cloud** : Élimination de la gestion d'infrastructure ; disponibilité garantie à 99,95%.
- **Collections multiples** : `raw_sources`, `normalised_sources`, `enriched_signals` et `temporal_signals` coexistent dans la même instance.

3.2 Neo4j — Graphe de Citations HITS

Neo4j est une base de données orientée graphes. Elle est utilisée **exclusivement** pour modéliser et stocker le graphe de citations entre sources médicales, nécessaire au calcul des scores HITS.

- **Nœuds (Source)** : chaque plateforme (PubMed, WebMD, Reddit...).
- **Relations (:CITE)** : indiquent qu'une source en référence une autre.
- **Cypher** : le langage de requête natif de Neo4j permet d'exprimer des traversées de graphe en quelques lignes, là où SQL nécessiterait des jointures récursives complexes.
- **Complémentarité** : les scores calculés dans Neo4j sont réinjectés dans MongoDB pour enrichir chaque document de son score de fiabilité.

4 Collecte et Extraction des Données

4.1 Choix des Sources

Dans Bio-Sentry, les sources de données sont sélectionnées afin de combiner fiabilité scientifique, données officielles et retours patients en conditions réelles.

TABLE 1 – Sources de données utilisées dans Bio-Sentry

Source	Description
ClinicalTrials	Source la plus fiable, basée sur des essais cliniques contrôlés. Fournit des données validées sur l'efficacité et la sécurité des médicaments.
MedlinePlus	Source médicale officielle proposant des informations validées et vulgarisées sur les médicaments, les maladies et les effets secondaires.
PubMed	Base de données scientifique regroupant des articles biomédicaux et des études de recherche validées.
OpenFDA (FAERS)	Base officielle de pharmacovigilance contenant des rapports d'effets indésirables en conditions réelles.
WebMD	Plateforme grand public fournissant des données issues de notices médicales, notamment les effets secondaires des médicaments.
Drugs.com	Source de retours patients en conditions réelles, permettant l'analyse des effets secondaires ressentis et de l'efficacité perçue.
Reddit	Source communautaire utilisée pour la détection de tendances émergentes, d'expériences patients spontanées et de signaux faibles non structurés.

4.2 Construction de la Référence Médicamenteuse (RxNorm)

Avant de lancer les scrapers, il faut répondre à un problème simple : le même médicament s'appelle différemment selon les plateformes. *Advil*, *ibuprofen* ou *Ibu-200* — des noms différents selon les sources, mais une seule et même molécule.. Sans référentiel commun, ces données restent fragmentées et impossibles à croiser automatiquement.

C'est le rôle de **RxNorm** : une base terminologique officielle qui attribue à chaque médicament un identifiant unique, le **RxCUI**. Nous l'avons choisi pour trois raisons concrètes :

- son API est gratuite et officiellement maintenue par la NLM (National Library of Medicine) ;
- il est compatible avec les standards FDA et les bases cliniques américaines ;
- il couvre à la fois les noms génériques, commerciaux et les synonymes régionaux.

Pour interroger l'API RxNorm, on utilise les **codes ATC** (*Anatomical Therapeutic Chemical*), qui regroupent les médicaments par famille thérapeutique. Nous avons retenu huit familles, choisies parce qu'elles concentrent la majorité des effets indésirables signalés en pharmacovigilance :

Catégorie	Code ATC	Justification
NSAID	M01A	Anti-inflammatoires très consommés
Antibiotique	J01	Résistances et effets fréquents
Antidépresseur	N06A	Effets psychologiques souvent mal signalés
Antihypertenseur	C02	Traitement chronique, risques d'interactions
Anticoagulant	B01A	Risque hémorragique élevé
Statine	C10AA	Effets musculaires souvent sous-déclarés
Antidiabétique	A10	Surveillance glycémique critique
Corticoïde	H02	Effets systémiques multiples

TABLE 2 – Catégories thérapeutiques retenues pour la construction de `drug_list`

Comment fonctionne le script `rxnorm_builder.py` ?

Le script s'exécute une seule fois, avant le lancement des scrapers. Il suit trois étapes :

1. **Récupération par catégorie** : pour chaque code ATC, la fonction `get_drugs_by_atc()` interroge l'endpoint `/rxclass/classMembers.json` de l'API RxNorm et retourne la liste des molécules avec leur `rxcul` et leur nom générique.
2. **Enrichissement en synonymes** : pour chaque `rxcul` récupéré, la fonction `get_synonyms()` appelle `/rxcul/{id}/allrelated.json` et collecte tous les noms alternatifs connus (génériques, commerciaux, variantes orthographiques).
3. **Stockage dans MongoDB** : chaque document est inséré ou mis à jour dans la collection `drug_list` via un `upsert` sur le champ `rxcul`, ce qui évite les doublons lors des ré exécutions.

Un document typique de `drug_list` a la structure suivante :

```
{
  "rxcul": "5640",
  "name": "ibuprofen",
  "category": "NSAID",
  "atc_code": "M01A",
  "synonyms": ["advil", "ibu-200", "brufen", "nurofen", ...],
  "updated_at": ISODate("2025-...")
}
```

Grâce à ce référentiel, un avis mentionnant *Advil* et un rapport OpenFDA mentionnant *ibuprofen* partagent le même `rxcul` : ils peuvent être agrégés, comparés et analysés ensemble dans les étapes suivantes du pipeline.

4.3 Extraction par Source

Les scrapers s'appuient sur la collection `drug_list` décrite ci-dessus. Pour chaque médicament, les recherches sont lancées sur le nom générique **et** sur l'ensemble des synonymes, ce qui garantit :

- une cohérence entre les différentes sources ;
- une standardisation des requêtes de recherche ;
- une simplification du processus de reprise automatique ;
- une meilleure gestion des doublons.

4.3.1 MedlinePlus

L'extraction des données depuis *MedlinePlus* repose sur une approche de scraping automatisé utilisant **Selenium** et **BeautifulSoup**. Le système parcourt automatiquement les pages de médicaments disponibles dans l'index alphabétique A→Z de la plateforme afin de collecter des informations biomédicales structurées liées aux traitements médicaux.

Le scraper récupère plusieurs types d'informations médicales, notamment :

- le nom du médicament,
- la classe thérapeutique,
- les indications médicales,
- les noms commerciaux,
- les effets secondaires bénins et graves,
- ainsi que les avertissements médicaux importants.

Une phase importante de nettoyage et de normalisation des données textuelles est également appliquée afin de supprimer les caractères parasites, les doublons et les contenus non pertinents extraits du HTML.

Les effets secondaires sont automatiquement classés en deux catégories :

- **Mild Side Effects** : effets secondaires courants ou bénins,
- **Serious Side Effects** : effets secondaires graves nécessitant une attention médicale.

Le système utilise également un mécanisme de filtrage et de structuration des données afin d'obtenir un dataset homogène exploitable dans les phases ultérieures de pharmacovigilance et d'analyse comportementale.

Fonctions principales :

- `get_all_drug_links(driver, limit)` : collecte automatiquement les URLs des médicaments depuis l'index alphabétique de MedlinePlus.
- `scrape_drug(driver, url)` : extrait l'ensemble des informations médicales d'un médicament donné.
- `get_drug_name(soup)` : récupère le nom principal du médicament.
- `get_drug_class(soup)` : extrait la classe thérapeutique du médicament.
- `get_prescribed_for(soup)` : récupère les indications thérapeutiques et usages médicaux.
- `get_side_effects(soup)` : extrait et catégorise les effets secondaires bénins et graves.
- `get_brand_names(soup)` : récupère les différents noms commerciaux associés au médicament.
- `get_warnings(soup)` : extrait les avertissements médicaux importants et les boxed warnings.

4.3.2 OpenFDA

L'API officielle de la FDA (`api.fda.gov/drug/event.json`) est exploitée afin d'accéder aux données du système *FAERS* FDA Adverse Event Reporting System), qui centralise les déclarations d'événements indésirables médicamenteux signalés aux autorités sanitaires américaines.

L'extraction est réalisée via des requêtes HTTP directes avec la bibliothèque `requests`, sans utilisation de navigateur automatisé. Pour chaque médicament présent dans la collection `drug_list`, le système interroge l'API OpenFDA afin de récupérer des rapports structurés.

Le système implémente également des mécanismes de gestion des limitations de l'API, notamment la détection des réponses 429 (*rate limit*)

Fonctions principales :

- `fetch_fda_reports(drug_name, category)` : récupération paginée des rapports via le paramètre `skip`, avec arrêt automatique lorsque la limite ou le total est atteint.
- `extract_reactions(reactions)` : extraction jusqu'à 6 effets indésirables structurés selon la terminologie MedDRA.
- `extract_drug_info(drugs, target)` : identification du médicament cible et extraction des informations associées (posologie, indication).

4.3.3 Drugs.com

Une extraction basée sur `requests` et `BeautifulSoup` est mise en œuvre, sans utilisation de navigateur réel ni d'automatisation via Selenium. Le système accède directement aux pages HTML publiques de `Drugs.com` afin de récupérer les avis utilisateurs et les retours liés aux médicaments.

Afin de limiter les mécanismes de détection et de blocage, plusieurs stratégies de protection sont appliquées :

- rotation dynamique des *User-Agents* ;
- renouvellement périodique des sessions HTTP ;
- temporisations aléatoires entre les requêtes et les pages ;
- gestion des erreurs HTTP (403, 429) avec mécanismes de reprise automatique.

Les données extraites sont ensuite analysées avec `BeautifulSoup` afin d'identifier les blocs d'avis, les notes utilisateurs, les conditions médicales associées ainsi que les commentaires textuels décrivant les effets secondaires observés.

Fonctions principales :

- `build_reviews_url(drug, page)` : génération dynamique des URLs de pagination des avis.
- `fetch_drug_reviews(...)` : parcours des avis et stockage direct dans MongoDB avec mécanisme de reprise automatique.
- `parse_review(card)` : extraction des informations d'un avis (texte, note, date, condition) via sélecteurs CSS et expressions régulières.

4.3.4 PubMed

L'API officielle de PubMed (eutils.ncbi.nlm.nih.gov/entrez/eutils/) est exploitée afin d'accéder à la base de données biomédicale du NCBI, qui centralise des millions d'articles scientifiques, d'études cliniques et de publications de recherche médicale validées par des pairs.

L'extraction est réalisée via des requêtes HTTP directes avec la bibliothèque `requests`, sans utilisation de navigateur automatisé. Pour chaque médicament présent dans la collection `drug_list`, le système interroge l'API PubMed afin de récupérer des articles structurés contenant des mentions d'effets indésirables médicamenteux.

Le système implémente également des mécanismes de gestion des limitations de l'API, notamment la détection des réponses 429 (*rate limit*) et le respect des quotas d'accès NCBI.

Fonctions principales :

- `fetch_pubmed_articles(drug_name, category)` : récupération paginée des articles via les paramètres `esearch` et `efetch`, avec arrêt automatique lorsque la limite ou le total est atteint.
- `extract_mesh_terms(article)` : extraction des termes MeSH associés à l'article pour identifier les effets indésirables selon la terminologie biomédicale standardisée.
- `extract_article_info(article, target)` : identification du médicament cible et extraction des informations associées (titre, résumé, date de publication, auteurs).

4.3.5 ClinicalTrials

L'API officielle de ClinicalTrials.gov (clinicaltrials.gov/api/query/full_studies) est exploitée afin d'accéder aux données des essais cliniques contrôlés enregistrés auprès des autorités sanitaires américaines, constituant la source la plus fiable du pipeline Bio-Sentry.

L'extraction est réalisée via des requêtes HTTP directes avec la bibliothèque `requests`, sans utilisation de navigateur automatisé. Pour chaque médicament présent dans la collection `drug_list`, le système interroge l'API ClinicalTrials afin de récupérer des rapports structurés sur les effets indésirables observés lors des essais cliniques.

Le système implémente également des mécanismes de gestion des limitations de l'API, notamment la pagination via le paramètre `min_rnk` et la gestion des délais de réponse.

Fonctions principales :

- `fetch_trials(drug_name, category)` : récupération paginée des essais cliniques via le paramètre `min_rnk`, avec arrêt automatique lorsque la limite ou le total est atteint.
- `extract_adverse_events(study)` : extraction des événements indésirables structurés selon la terminologie MedDRA, incluant leur fréquence et leur sévérité observées durant l'essai.
- `extract_study_info(study, target)` : identification du médicament cible et extraction des informations associées (phase, statut, nombre de participants, indication thérapeutique).

4.3.6 Reddit

L'extraction repose sur les endpoints JSON publics de Reddit (`/search.json` et `/comments.json`), sans utilisation d'authentification API. Le système effectue des recherches ciblées dans plusieurs subreddits médicaux spécialisés tels que `AskDocs`, `pharmacy` ou `Medications`.

Un filtrage basé sur des mots-clés biomédicaux est appliqué afin de conserver uniquement les publications potentiellement liées aux effets secondaires médicamenteux. Cette approche repose sur :

- la détection de symptômes physiques ou psychologiques,
- l'identification de termes exprimant une relation entre le médicament et l'effet observé,
- ainsi que la présence explicite du nom du médicament dans le contenu analysé.

Fonctions principales :

- `is_side_effect_relevant(text, drug_slug)` : filtre les messages contenant le médicament et des termes de symptômes ou de causalité.
- `search_subreddit_for_drug(subreddit, drug_slug, after)` : gestion de la recherche paginée.
- `fetch_post_comments(subreddit, post_id, drug_slug, category)` : extraction et filtrage des commentaires pertinents.

4.3.7 WebMD

Dans ce site, les informations collectées proviennent des fiches médicales et des sections “Side Effects” disponibles sur la plateforme.

L'extraction des données est réalisée à l'aide de Selenium afin de reproduire une navigation proche du comportement humain. Le scraper accède automatiquement à la page de recherche WebMD, sélectionne le médicament correspondant, puis navigue vers l'onglet des effets secondaires pour extraire directement les informations depuis le DOM de la page :

- `find_webmd_url_selenium(drug_name, synonyms)` : recherche et accès à la page du médicament.
- `_search_and_click()` : navigation vers la fiche médicament.
- `_click_sideeffects_tab()` : accès à la section *Side Effects*.
- `_extract_effects_from_dom()` : extraction des données directement depuis le DOM via JavaScript.

```
...
{'_id': 'openfda', 'count': 7000}
{'_id': 'drugs.com', 'count': 4819}
{'_id': 'reddit', 'count': 2161}
{'_id': 'medlineplus', 'count': 1979}
{'_id': 'pubmed', 'count': 1601}
{'_id': 'clinicaltrials', 'count': 382}
{'_id': 'webmd', 'count': 371}
```

FIGURE 2 – Total de scraping

5 Axe 1 : Web Content Mining & NLP Biomédical

Les textes collectés depuis les sources médicales sont hétérogènes : articles scientifiques, avis patients, rapports d’essais cliniques. Pour en extraire les effets secondaires de façon cohérente, nous avons mis en place un pipeline NLP en quatre étapes.

Étape 1 — Détection lexicale préliminaire

Avant tout traitement neuronal, le texte est comparé à deux dictionnaires de termes connus : effets secondaires et symptômes. Cette passe rapide produit des *seeds* qui servent de filet de sécurité si le modèle NER manque certains termes. Les mentions de posologie (valeurs numériques suivies d’une unité : mg, µg, ml...) sont aussi extraites à cette étape par expression régulière.

Étape 2 — Reconnaissance d’entités biomédicales (NER)

Modèle utilisé : SciBERT-NER (*fran-martinez/scibert-ner-medical*).

Le texte est soumis à ce modèle pour identifier automatiquement les entités médicales pertinentes. Il retourne quatre types d’entités :

- DRUG — le nom du médicament mentionné ;
- DISEASE — la maladie ou condition médicale ;
- SYMPTOM — le symptôme ou effet observé ;
- DOSAGE — la dose associée (ex. 200 mg).

Comme les textes peuvent être longs, le modèle les traite en fenêtres glissantes afin de respecter la limite de tokens des transformeurs. Les entités dupliquées sont ensuite éliminées avant de passer à l’étape suivante.

Nous avons choisi SciBERT car il est entraîné sur un large corpus scientifique (Semantic Scholar), ce qui le rend adapté à la diversité de nos sources : aussi bien un article PubMed qu’un avis patient sur Drugs.com ou un rapport OpenFDA.

Étape 3 — Classification de la relation

Modèle utilisé : BioBERT (*dmis-lab/biobert-base-cased-v1.2*).

Une fois les entités détectées, il reste à trancher : s’agit-il d’un **effet secondaire** causé par le médicament, ou d’un **symptôme** de la maladie sous-jacente ?

Nous avons choisi BioBERT plutôt que ClinicalBERT pour cette étape : BioBERT est entraîné sur PubMed et PMC, ce qui le rend adapté à la variété de nos sources (avis patients, rapports FDA, articles scientifiques). ClinicalBERT, lui, est spécialisé sur les notes cliniques hospitalières — un format absent de notre pipeline.

BioBERT encode le contexte autour de l'entité ; une régression logistique prédit la relation. Si la confiance est inférieure à **0,82**, un second niveau prend le relais : des expressions régulières comptent les indices contextuels (*induced by*, *adverse reaction* pour les effets secondaires ; *diagnosed with*, *underlying disease* pour les symptômes). La classe majoritaire l'emporte.

Étape 4 — Normalisation terminologique

Les entités retenues sont normalisées via deux tables de correspondance : d'abord un dictionnaire d'alias orthographiques, puis une table inspirée de **MedDRA** qui regroupe les formulations proches sous un terme unique (*brain fog*, *confusion* et *forgetfulness* deviennent tous *memory impairment*). Les résultats sont ensuite écrits dans MongoDB par lots de 50 documents.

Résumé du flux




FIGURE 3 – Pipeline NLP de l'Axe 1 — Bio-Sentry

6 Axe 2 : Score de Fiabilité des Sources (HITS)

6.1 Pourquoi noter les sources ?

Toutes les sources d'information médicale ne possèdent pas le même niveau de fiabilité. Un article scientifique publié sur PubMed est généralement validé par des experts, tandis qu'un contenu provenant de Reddit peut être non vérifié. Bio-Sentry attribue automatiquement un score de fiabilité à chaque source en utilisant un **algorithme de classement basé sur la structure des citations**.

6.2 L'algorithme HITS

L'algorithme **HITS** (*Hyperlink-Induced Topic Search*) est initialement utilisé pour classer les pages web en fonction de leurs liens. Dans ce projet, il est adapté à un **graphe de citations entre sources médicales**, où une relation WebMD $\rightarrow$ PubMed signifie que WebMD s'appuie sur une source plus fiable.

Deux indicateurs sont calculés pour chaque source :

- **Authority score** : une source est considérée comme une autorité si elle est fortement citée par d'autres sources.
- **Hub score** : une source est considérée comme un hub si elle référence fréquemment des sources fiables.

6.3 Résultats

Après convergence de l'algorithme (environ 15 itérations), les scores sont normalisés entre 0 et 1. Les résultats permettent de classer automatiquement les sources selon leur niveau de fiabilité, du plus fiable (PubMed) au moins fiable (Reddit).

HITS – Scores de confiance des sources				
Source	Type	Authority	Hub	Dist
PubMed	authority	1.0000	0.0000	0
ClinicalTrials.gov	authority	0.8880	0.3035	0
OpenFDA (FAERS)	authority	0.8573	0.5730	0
MedlinePlus	authority	0.5498	0.8331	0
WebMD	hub	0.2069	1.0000	1
Drugs.com	hub	0.0261	0.4898	1
Reddit	hub	0.0000	0.0707	2

FIGURE 4 – score de confiance des sources

Les résultats confirment le classement épistémique attendu : PubMed, ClinicalTrials.gov et OpenFDA obtiennent les scores d'autorité les plus élevés (respectivement 1,0000, 0,8880 et 0,8573) et une distance structurelle de 0, tandis que Reddit se trouve à l'opposé avec un score nul et une distance de 2 sauts. Ces scores sont propagés dans MongoDB afin de pondérer chaque assertion selon la fiabilité de sa source d'origine.

Ces scores sont ensuite :

- stockés dans **Neo4j** sous forme de graphe de citations,
- intégrés dans **MongoDB** pour enrichir chaque document analysé.

6.4 Modélisation du Graphe (Neo4j)

Les sources sont représentées sous forme de nœuds (**Source**) et les relations de citation sous forme d'arêtes : **CITE**. Le graphe permet de modéliser la hiérarchie de confiance entre les différentes plateformes biomédicales et d'exploiter cette structure dans les analyses ultérieures.




FIGURE 5 – graphe de citations

7 Pipeline de Normalisation et Enrichissement

Ce pipeline orchestre les Axes 1 (NLP) et 2 (HITS) afin de produire la collection `normalised_sources`, contenant un schéma unifié regroupant l'ensemble des informations extraites et enrichies.

7.1 Chargement des Scores HITS

Au démarrage du système, le pipeline HITS est exécuté afin de calculer :

- le score d'autorité (*Authority score*),

- le score de hub (*Hub score*).

7.2 Normalisation par Source

Les données proviennent de sources hétérogènes possédant des structures différentes. Chaque source dispose donc d'un normaliseur dédié, permettant d'unifier les formats vers un schéma standard. Le système supporte également un mode parallèle (`-source`) pour exécuter chaque source indépendamment.

7.3 Classification NLP

À l'aide du module `nlp_biobert.py`, chaque document est analysé afin d'extraire trois types d'informations principales :

- `side_effects`
- `symptoms`
- `dosages`

7.4 Filtrage des Documents Non Informatifs

Les documents ne contenant aucune information exploitable sont automatiquement supprimés. Sont exclus les cas où `symptoms` et `side_effects` sont tous deux vides.

7.5 Déduplication et Stockage

Avant insertion dans MongoDB, une déduplication est appliquée sur plusieurs clés :

- URL,
- `source_id`,
- ou hash de contenu (si aucune clé n'est disponible).

Les données finales sont stockées dans la collection `normalised_sources`.

7.6 Normalisation Temporelle des Signaux

Une étape supplémentaire extrait, nettoie et structure les informations temporelles associées aux événements médicaux. Les signaux sont stockés dans `temporal_signals`, puis agrégés avec `normalised_sources` pour produire `enriched_signals` — base adaptée aux tâches de machine learning et à l'analyse prédictive en pharmacovigilance.

7.7 Contrôle Qualité des Données

Collecter beaucoup de données ne suffit pas — encore faut-il savoir lesquelles sont fiables. Après la déduplication, chaque document de `normalised_sources` passe par un contrôle qualité automatique implémenté dans `quality_flags.py`. Ce script attribue à chaque document un score numérique et un label de qualité, stockés dans la collection `quality_flags`.

Calcul du score

Chaque document commence avec un score de 100. Six vérifications sont ensuite appliquées, chacune pouvant déduire des points :

Critère	Flag	Pénalité
Champ manquant (<code>drug_name</code> , <code>source</code> , <code>text_clean</code> , <code>side_effects</code>)	<code>missing_fields</code>	-10/champ
Texte inférieur à 50 caractères	<code>text_too_short</code>	-15
Texte entre 50 et 100 caractères	<code>text_short</code>	-5
Aucun effet secondaire détecté	<code>no_side_effects</code>	-10
Score HITS absent ou inférieur à 0,1	<code>low_authority</code>	-5
Nom du médicament absent	<code>missing_drug_name</code>	-20
Source non reconnue dans le pipeline	<code>unknown_source</code>	-10

TABLE 3 – Critères de qualité appliqués par `quality_flags.py`

Le score final est ensuite converti en trois labels :

- **good** : score ≥ 80 — document exploitable sans réserve ;
- **medium** : score entre 50 et 79 — document utilisable avec précaution ;
- **poor** : score < 50 — document écarté des analyses critiques.

Lien avec les autres composants

Ce contrôle qualité s’appuie directement sur deux éléments déjà construits dans le pipeline :

- le champ `source_authority`, issu du score HITS calculé en Axe 2, est réutilisé ici comme indicateur de fiabilité ;
- le champ `side_effects`, produit par le pipeline NLP de l’Axe 1, détermine si le document contient une information exploitable pour la pharmacovigilance.

Les résultats sont sauvegardés dans la collection `quality_flags`, qui contient pour chaque document : le score, le label, la liste des flags déclenchés, la longueur du texte et la date du contrôle. Cette collection alimente ensuite les étapes d’analyse et de détection d’anomalies de l’Axe 3, en excluant automatiquement les documents de mauvaise qualité.

8 Axe 3 : Web Usage Mining — Surveillance Épidémiologique

8.1 Objectif

L’Axe 3 vise la **détection d’anomalies temporelles** dans les flux de données médicales afin d’identifier l’émergence précoce de signaux de pharmacovigilance. Il inclut également le **clustering des profils de risque médicamenteux** pour modéliser les trajectoires de soins et anticiper les tensions sur les infrastructures de santé.

8.2 Données utilisées

Les analyses reposent sur la collection `data_aggregation` (19 974 documents) issue du pipeline de traitement Bio-Sentry. Chaque document représente une combinaison unique `drug` + `side_effect` + `period` avec son `mention_count` agrégé.

8.2.1 Nettoyage et Biais

La période **2019-01** a été exclue de l’analyse car elle représente une agrégation artificielle de données historiques sans date précise, introduisant un biais statistique dans la détection d’anomalies. Cette décision réduit le dataset de 20,3% mais améliore significativement la qualité des résultats.

“La période 2019-01 correspond à une agrégation de données historiques de Drugs.com dont les dates exactes ne sont pas disponibles.”

8.2.2 Distribution temporelle finale

TABLE 4 – Distribution des documents par année après nettoyage

Année	Documents	Observation
2019	7 038	depuis le mois 2
2020	3 146	Normal
2021	2 176	Normal
2022	1 789	Normal
2023	1 721	Normal
2024	1 676	Normal
2025	1 484	Normal
2026	944	Année incomplète
Total	19 974	

8.3 Détection d’Anomalies — 3 Algorithmes Comparés

Conformément aux exigences du cahier des charges, l’analyse repose sur une **étude comparative de trois approches algorithmiques distinctes** pour garantir la robustesse des prédictions.

8.3.1 Local Outlier Factor (LOF)

LOF est un algorithme non supervisé qui mesure la **densité locale** de chaque point par rapport à ses voisins. Un point est considéré anomal si sa densité locale est significativement inférieure à celle de ses voisins.

Paramètres utilisés :

— `n_neighbors` = 30

- `contamination = "auto"` — le seuil est déterminé **automatiquement** par l'algorithme selon la distribution réelle des données, sans biais artificiel imposé par le chercheur.

Résultats :

Métrique	Valeur
Documents analysés	19 974
Anomalies détectées	372
Taux d'anomalies	1,9%
Seuil	Automatique

TABLE 5 – Résultats LOF

Le taux de **1,9%** est cohérent avec les taux observés dans les bases de pharmacovigilance officielles FDA et EMA (1–3%), validant la pertinence du modèle.

8.3.2 Isolation Forest

Isolation Forest isole les anomalies en construisant des **arbres de décision aléatoires**. Les points anomaux sont isolés plus rapidement car ils se situent loin de la masse des données normales.

Paramètres :

- `n_estimators = 100`
- `random_state = 42`
- Seuil : **IQR Tukey** calculé automatiquement sur les scores IF ($Q_1 = 0,3675$, $Q_3 = 0,4845$, $IQR = 0,1170$, seuil = 0,6600)

Avantage : Particulièrement efficace pour les données multidimensionnelles et les espaces de grande dimension. Le seuil IQR Tukey évite tout biais de paramétrage manuel en s'adaptant à la distribution réelle des scores d'anomalie.

Résultats :

Métrique	Valeur
Documents analysés	19 974
Anomalies détectées	495
Taux d'anomalies	2,5%
Seuil IQR Tukey	0,6600

TABLE 6 – Résultats Isolation Forest

8.3.3 Z-Score Rolling

Le Z-Score Rolling est une variante temporelle du Z-Score classique : au lieu de comparer chaque observation à la moyenne globale, il compare chaque valeur à la **moyenne**

glissante locale de son groupe `drug + side_effect`, avec une fenêtre temporelle **adaptée automatiquement** à la taille du groupe.

Paramètres :

- Seuil d'anomalie : $|Z_{rolling}| > 3$
- Fenêtre (`window_auto`) : déterminée automatiquement selon la taille de chaque groupe (1 à 6 mois)

Avantage : capture les pics temporels locaux indépendamment du volume global, adapté aux séries chronologiques irrégulières.

Distribution des fenêtres automatiques :

Fenêtre (mois)	Nombre de groupes
1	1 193
2	285
3	154
4	58
5	26
6	3

TABLE 7 – Distribution des fenêtres glissantes automatiques (Z-Score Rolling)

Résultats :

Métrique	Valeur
Documents analysés	19 974
Anomalies détectées	252
Taux d'anomalies	1,3%
Seuil	$ Z_{rolling} > 3$

TABLE 8 – Résultats Z-Score Rolling

8.3.4 Comparaison et Consensus des 3 Algorithmes

Les résultats des trois algorithmes sont stockés dans la collection `ml_predictions` (19974 documents) avec les champs : `lof_anomaly`, `iforest_anomaly`, `zscore_anomaly`.

Synthèse comparative des 3 algorithmes :

Algorithme	Anomalies	Taux	Méthode de seuillage
LOF	372	1,9%	Automatique (densité locale)
Isolation Forest	495	2,5%	IQR Tukey (<i>seuil</i> = 0,66)
Z-Score Rolling	252	1,3%	$ Z_{rolling} > 3$

TABLE 9 – Synthèse comparative des 3 algorithmes de détection d'anomalies

Un système de **consensus** a été mis en place pour définir le niveau d'alerte final en fonction du nombre d'algorithmes détectant une anomalie :

Niveau	Consensus	Documents	%
NORMAL	0/3 algorithmes	18 972	95,0%
MODÉRÉ	1/3 algorithmes	885	4,4%
ÉLEVÉ	2/3 algorithmes	117	0,6%
CRITIQUE	3/3 algorithmes	0	0,0%

TABLE 10 – Distribution des niveaux d'alerte — consensus des 3 algorithmes

Interprétation :

L'absence de consensus total (3/3) reflète la **complémentarité** des approches algorithmiques : chaque modèle capture une dimension différente de l'anomalie. LOF détecte les ruptures de densité locale, Isolation Forest identifie les points isolés dans l'espace multidimensionnel, et le Z-Score Rolling repère les pics temporels locaux. Les **117 signaux élevés** (0,6%) détectés par au moins 2 algorithmes simultanément constituent les alertes prioritaires de Bio-Sentry.

8.3.5 Justification du choix des 3 algorithmes

- **LOF (Local Outlier Factor)** a été choisi car **85,6%** des valeurs de `mention_count` sont égales à 1 — des données fortement déséquilibrées, caractéristique inhérente à la pharmacovigilance. LOF est parfaitement adapté à ce type de distribution car il travaille sur la **densité locale** et non sur des seuils globaux : il détecte les anomalies en comparant chaque point à ses voisins immédiats, sans être perturbé par la distribution globale. Il identifie ainsi des effets indésirables rares mais localement anormaux, invisibles pour des méthodes globales. Taux de détection : **1,9%**, cohérent avec les bases de pharmacovigilance officielles FDA et EMA (1–3%).
- **Isolation Forest** a été choisi car les données sont **multidimensionnelles** — médicament, effet secondaire, période, `mention_count` — et Isolation Forest gère efficacement les espaces de grande dimension sans supposer une distribution particulière. Il isole les anomalies via des arbres de décision aléatoires : les points aberrants sont isolés plus rapidement car ils se situent loin de la masse des données normales. Son seuillage automatique par **IQR Tukey** (*seuil* = 0,66) évite

tout biais de paramétrage manuel en s’adaptant à la distribution réelle des scores d’anomalie. Taux de détection : **2,5%**.

- **Z-Score Rolling** a été choisi car Bio-Sentry travaille sur des **séries temporelles irrégulières**. Contrairement au Z-Score classique qui compare chaque observation à la moyenne globale, sa **fenêtre glissante adaptative** (1 à 6 mois, déterminée automatiquement selon la taille de chaque groupe) capture les pics temporels locaux pour chaque groupe `drug + side_effect`, indépendamment du volume global. Cette approche est particulièrement adaptée aux données de pharmacovigilance où un signal peut émerger brutalement sur une courte période sans être visible à l’échelle globale. Son seuil conservateur ($|Z_{rolling}| > 3$) garantit une haute précision en limitant les faux positifs. Taux de détection : **1,3%**.

Ensemble, ces trois algorithmes couvrent les trois dimensions complémentaires de la détection d’anomalies en pharmacovigilance :

Algorithme	Dimension	Type d’anomalie détectée	Taux
LOF	Densité locale	Effets rares localement anormaux	1,9%
Isolation Forest	Isolation spatiale	Comportements globalement atypiques	2,5%
Z-Score Rolling	Dérive temporelle	Pics soudains sur séries irrégulières	1,3%

TABLE 11 – Dimensions complémentaires couvertes par les 3 algorithmes

Cette architecture multi-algorithmes garantit qu’aucun signal pharmacovigilant significatif n’est manqué par un angle mort d’un modèle unique, tout en s’appuyant sur le **consensus** pour hiérarchiser la criticité des alertes et minimiser les faux positifs soumis à l’analyse humaine.

8.4 Clustering — 3 Algorithmes Comparés

Conformément aux exigences du cahier des charges, l’analyse repose sur une **étude comparative de trois approches algorithmiques distinctes** pour garantir la robustesse de la segmentation des couples `drug + side_effect + period`.

8.4.1 K-Means

K-Means est un algorithme de clustering par **partitionnement** qui regroupe les données en k clusters en minimisant la variance intra-cluster. Chaque point est assigné au centroïde le plus proche de manière itérative.

Paramètres utilisés :

- `n_clusters` = 4
- `random_state` = 42
- `n_init` = 10 — nombre de réinitialisations pour éviter les minima locaux.

Résultats :

Métrique	Valeur
Documents analysés	19 974
Clusters produits	4
Silhouette Score	0,3196
Calinski-Harabasz	2852,68
Davies-Bouldin	1,1164

TABLE 12 – Résultats K-Means

Le Silhouette Score de **0,32** indique une séparation modérée des clusters, cohérente avec la nature multidimensionnelle et déséquilibrée des données de pharmacovigilance.

8.4.2 Agglomerative Clustering

L'Agglomerative Clustering est un algorithme **hiérarchique ascendant** : il commence par considérer chaque point comme un cluster individuel, puis fusionne progressivement les clusters les plus proches selon un critère de liaison.

Paramètres :

- `n_clusters = 4`
- `linkage = "ward"` — minimise la variance totale intra-cluster lors de chaque fusion, produisant des clusters compacts et équilibrés.

Avantage : La liaison Ward est particulièrement adaptée aux données normalisées et multidimensionnelles. Elle produit des clusters plus homogènes que les liaisons *complete* ou *average*.

Résultats :

Métrique	Valeur
Documents analysés	19 974
Clusters produits	4
Silhouette Score	0,5528
Calinski-Harabasz	2942,81
Davies-Bouldin	0,9364

TABLE 13 – Résultats Agglomerative Clustering

8.4.3 HDBSCAN

HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) est un algorithme de clustering **basé sur la densité** qui détecte automatiquement le nombre de clusters et identifie les points aberrants sans les forcer dans un groupe. **Paramètres :**

- `min_cluster_size = 100` — déterminé par scan automatique des hyperparamètres avec optimisation du Silhouette Score.

- `min_samples = 20`
- `metric = "euclidean"`
- Réduction dimensionnelle préalable par **PCA** (variance expliquée $\geq 95\%$, 5 composantes retenues).

Avantage : HDBSCAN ne nécessite pas de spécifier le nombre de clusters a priori et gère nativement le bruit. Un filtrage préalable sépare les couples à mention unique (`total_mentions` ≤ 1 , étiquetés `cluster = -2`) des signaux exploitables (`total_mentions` ≥ 2).

Résultats :

Métrique	Valeur
Documents analysés	19 974
Couples bruit (cluster -2)	6 252
Outliers (cluster -1)	527
Clusters normaux	3
Silhouette Score	0,3060

TABLE 14 – Résultats HDBSCAN

8.4.4 Comparaison des 3 Algorithmes

Les résultats des trois algorithmes sont fusionnés dans la collection `data_clustering` (19974 documents) avec les champs : `kmeans_cluster`, `agglo_cluster` et `hdbscan_cluster`.

Synthèse comparative des 3 algorithmes :

Algorithme	Clusters	Silhouette	Calinski-Harabasz	Davies-Bouldin
K-Means	4	0,3196	2852,68	1,1164
Agglomerative (Ward)	4	0,5528	2942,81	0,9364
HDBSCAN	3	0,3060	885,70	2,1457

TABLE 15 – Synthèse comparative des 3 algorithmes de clustering

Interprétation des métriques :

- **Silhouette Score** : entre -1 et 1 , plus proche de 1 = meilleur clustering. Agglomerative obtient le meilleur score (**0,55**).
- **Calinski-Harabasz** : plus grand = clusters mieux séparés et compacts. Agglomerative domine (**2942,81**).
- **Davies-Bouldin** : plus petit = meilleur clustering. Agglomerative obtient le score le plus bas (**0,94**).

8.4.5 Justification du choix des 3 algorithmes de clustering

Le choix de combiner trois algorithmes distincts repose sur une logique de **complémentarité** : chaque modèle répond à une caractéristique spécifique du dataset Bio-Sentry.

- **K-Means** est performant sur notre dataset car les données ont été préalablement **normalisées** (StandardScaler) et réduites dimensionnellement par **PCA**. Il permet une segmentation rapide et efficace sur un grand volume de données tel que nos **19 974 documents**, en produisant k clusters distincts.
- **Agglomerative Clustering** est plus performant que d'autres méthodes hiérarchiques car il capture mieux les **relations de proximité** entre les signaux médicaux. Avec la liaison **Ward**, qui minimise la variance totale intra-cluster à chaque fusion, il produit des clusters plus compacts et mieux séparés.
- **HDBSCAN** est particulièrement adapté à notre dataset car celui-ci contient une forte proportion de **bruit et de signaux rares (6 252 couples à mention unique, soit 61,7% des données)**. Contrairement à K-Means ou DBSCAN classique, HDBSCAN **détecte automatiquement** le nombre de clusters et identifie les outliers sans forcer tous les points dans un groupe. Cette propriété est fondamentale en pharmacovigilance : les effets secondaires rares sont précisément les signaux les plus critiques à surveiller.

En synthèse, chaque modèle répond à une caractéristique spécifique du dataset :

Algorithme	Rôle principal	Caractéristique exploitée
K-Means	Segmentation globale rapide	Données normalisées et réduites par PCA
Agglomerative (Ward)	Qualité des clusters	Relations de proximité entre signaux médicaux
HDBSCAN	Gestion du bruit et anomalies	Signaux rares et effets secondaires critiques

TABLE 16 – Rôle complémentaire des 3 algorithmes de clustering

Cette architecture multi-modèles garantit à la fois une **segmentation globale robuste** des profils de risque et une **détection fine des signaux rares**, deux exigences complémentaires et indissociables d'un système de pharmacovigilance fiable.

9 Dashboard Interactif

Dans le cadre de ce projet, nous avons développé un tableau de bord web interactif nommé **Bio-Sentry**, dédié à la pharmacovigilance. Cette interface centralise l'ensemble des résultats produits par le pipeline de collecte, de traitement et d'analyse des données, et les rend accessibles à travers six modules distincts.

9.1 Vue d'Ensemble

La page d'accueil a été conçue pour offrir une lecture immédiate de l'état global du système. Elle synthétise les principaux résultats du projet à travers cinq indicateurs chiffrés :

le volume total de signalements traités (19 974), le nombre de médicaments couverts (326), le nombre d'effets indésirables identifiés (2 212), le nombre d'alertes critiques actives, ainsi que la période temporelle analysée, s'étendant de février 2019 à mai 2026.




FIGURE 6 – Page d'accueil du tableau de bord Bio-Sentry — vue d'ensemble des indicateurs clés

Pour restituer la dimension temporelle des données collectées, nous avons intégré une courbe d'évolution mensuelle du volume de mentions, toutes sources confondues. Cette courbe met en évidence un pic d'activité concentré au début de la période, suivi d'une stabilisation progressive. Un tableau des signaux les plus critiques complète cette vue, en listant les associations médicament/effet secondaire ayant été détectées par le plus grand nombre d'algorithmes simultanément. Des liens de navigation rapide permettent enfin d'accéder directement aux différents modules d'analyse.




FIGURE 7 – Page d'accueil du tableau de bord Bio-Sentry

9.2 Exploration de Contenu

Ce module a été développé pour permettre l’exploration et l’analyse de la distribution des effets indésirables extraits des sources surveillées. Quatre métriques globales y sont présentées : le nombre total de mentions extraites (25 152), la plage temporelle couverte, le nombre d’effets distincts recensés (2 212) et le mois de plus forte activité.

Nous avons mis en place deux filtres combinables permettant de restreindre dynamiquement l’ensemble des visualisations à un médicament ou un effet secondaire précis. Trois graphiques ont été construits pour explorer ces données sous différents angles. Un premier diagramme en barres classe les quinze effets indésirables les plus fréquents par volume de mentions, faisant ressortir l’anxiété comme effet le plus rapporté avec 1 410 occurrences, devant la dépression et la nausée. Un second graphique retrace l’évolution temporelle mensuelle de ces mentions sur l’ensemble de la période. Un troisième diagramme identifie les dix médicaments les plus mentionnés, avec le sulfathiazole en tête à 1 136 mentions. L’ensemble de ces graphiques est doté d’infobulles interactives affichant les valeurs précises au survol.




FIGURE 8 – Module d’exploration de contenu

9.3 Exploration de Structure

Ce module évalue la fiabilité de chaque source via l’algorithme **HITS**, qui classe les sources en *Authorities* (PubMed, OpenFDA, ClinicalTrials) et en *Hubs* (Reddit, forums patients). PubMed obtient le meilleur score d’autorité (0.95) et Reddit le meilleur score

Hub (0.91), pour une autorité moyenne de 0.75/1.00 sur les 6 sources indexées. Un graphique en barres, un nuage de points volume/autorité, un radar multicritères et une scorecard composite complètent cette analyse. OpenFDA ressort avec le score composite le plus élevé (0.960), suivi de Drugs.com (0.699) et PubMed (0.589).




FIGURE 9 – Scores d'autorité HITS et positionnement volume vs autorité par source




FIGURE 10 – Profil radar comparatif et scorecard composite des sources

9.4 Heatmap des Co-occurrences

Pour analyser les relations entre médicaments et effets indésirables, nous avons développé une carte de chaleur matricielle croisant les vingt médicaments les plus fréquents avec les vingt effets indésirables les plus rapportés. L'intensité de chaque cellule reflète le

volume de mentions agrégées pour chaque paire, selon une échelle allant du blanc pour une absence de co-occurrence jusqu'au rouge pour les associations les plus fréquentes.

Trois indicateurs synthétiques accompagnent cette visualisation : le nombre total de combinaisons distinctes identifiées (10 140), la paire la plus fréquente (sulfathiazole × abdominal discomfort), et la période ayant concentré le plus grand volume de signaux (février 2019, avec 2 459 co-occurrences). Parmi les associations les plus marquées figurent sulfanilamide × depression avec 44 co-occurrences et tiaprofenic acid × drug ineffective avec 88.

Deux mécanismes de filtrage ont été intégrés : une recherche par nom de médicament et un sélecteur de plage temporelle par glissement, permettant de recalculer la heatmap sur une période définie. Un tableau détaillé en bas de page restitue l'ensemble des co-occurrences avec leurs métriques complètes.




FIGURE 11 – Heatmap des co-occurrences médicaments $\times$ effets indésirables — intensité proportionnelle au volume de mentions

9.5 Recherche de Médicaments

Ce module permet de générer automatiquement le profil de sécurité d'un médicament donné à partir des données agrégées. L'utilisateur peut saisir librement un nom de médicament ou utiliser les raccourcis prédéfinis pour les molécules les plus courantes (Atorvastatin, Metformin, Rivaroxaban, Sertraline, Semaglutide, Ibuprofen, Omeprazole).

Le profil généré regroupe quatre indicateurs : le nombre total de rapports associés au médicament, le nombre de signaux actifs détectés, un score de risque calculé, et la taille de la cohorte de patients concernés. Une courbe d'évolution temporelle illustre la dynamique des mentions du médicament mois par mois sur toutes les sources surveillées. Un lien contextuel redirige vers la heatmap pré-filtrée sur ce médicament, facilitant l'exploration de ses co-occurrences spécifiques. À titre d'exemple, Atorvastatin ressort avec 95 rapports et 10 signaux actifs, contre 72 rapports sans signal actif pour Omeprazole.




FIGURE 12 – Module de recherche de médicaments — profil de sécurité de l'Atorvastatin

9.6 Détection d'Anomalies

Ce module constitue le cœur analytique du système. Nous y avons implémenté trois algorithmes de détection d'anomalies opérant en parallèle sur les séries temporelles des signaux pharmacovigilants : le Local Outlier Factor (LOF), l'Isolation Forest et le Z-Score. Chacun identifie les associations médicament/effet dont le comportement s'écarte significativement de la norme historique selon sa propre logique statistique ou structurelle.

Un mécanisme de consensus a été ajouté pour identifier les cas où les trois algorithmes s'accordent simultanément sur une même anomalie, constituant alors une alerte critique justifiant une investigation prioritaire. La répartition des détections est présentée sous forme de diagramme circulaire, distinguant les signaux détectés par un seul algorithme (LOF seul : 308, Isolation Forest seul : 379, Z-Score seul : 198) des détections croisées et du consensus. Un histogramme de distribution des mentions complète cette vue.

L'ensemble des anomalies signalées est restitué dans un tableau paginé indiquant, pour chaque entrée, le médicament, l'effet secondaire, la période de détection, le nombre de mentions, le résultat de chacun des trois algorithmes, et le niveau d'alerte attribué (ÉLEVÉ, MODÉRÉ ou NORMAL). Trois filtres combinables ont été intégrés pour permettre une exploration ciblée par niveau d'alerte, par algorithme déclencheur, ou par nom de médicament.




FIGURE 13 – Module de détection d'anomalies — résultats des algorithmes LOF, Isolation Forest et Z-

9.7 Clustering des Signaux

Le dernier module regroupe les signaux pharmacovigilants par similarité comportementale à l'aide de trois algorithmes de clustering non supervisé : K-Means, Agglomerative et HDBSCAN. L'utilisateur peut basculer entre les trois méthodes via des onglets dédiés et comparer leurs résultats respectifs.

Pour l'algorithme HDBSCAN, nous avons produit 4 clusters cohérents à partir des 19 974 signaux analysés, avec 6 252 points identifiés comme bruit et exclus de tout groupe. Un nuage de points représente la distribution spatiale des signaux selon leur nombre de périodes d'apparition et leur volume total de mentions. Un graphique en barres compare le poids de chaque cluster, et un tableau de synthèse en présente les caractéristiques dominantes. Le cluster principal regroupe 6 359 signaux autour de l'amitriptyline associée à la dépression, tandis qu'un second cluster de 3 056 signaux est structuré autour du sulfathiazole et des réactions médicamenteuses indésirables. Un tableau paginé détaille l'ensemble des signaux avec leur cluster d'appartenance, leur niveau de risque et leurs métriques associées.




FIGURE 14 – Module de clustering des signaux — distribution HDBSCAN et résumé des clusters identifiés

9.8 Qualité des Données

Ce module attribue à chaque source un score de qualité global sur 100, calculé à partir de quatre critères : score de base, fiabilité, couverture des effets secondaires et volume textuel. PubMed obtient le score le plus élevé (**90/100**), suivi de MedlinePlus (86), ClinicalTrials (83), WebMD (79), OpenFDA (73) et Reddit (68). Ces scores sont intégrés directement dans la pondération des signaux lors de la détection d'anomalies.




FIGURE 15 – Scores de qualité globaux par source — jauges et détail des composantes

10 Éthique et Conformité RGPD

Dans le cadre du projet **Bio-Sentry**, une attention particulière a été portée aux aspects éthiques, juridiques et réglementaires liés à la collecte et au traitement des données issues du web. Le système manipule des informations potentiellement sensibles provenant de plateformes médicales, communautaires et scientifiques ; il est donc essentiel de garantir une utilisation responsable et conforme aux réglementations en vigueur.

10.1 Respect du RGPD

Le projet respecte les principes fondamentaux du *Règlement Général sur la Protection des Données (RGPD)* appliqués au traitement des données numériques :

- **Minimisation des données** : seules les informations strictement nécessaires à l'analyse de pharmacovigilance sont collectées.
- **Absence de données personnelles identifiables** : aucune donnée permettant d'identifier directement un utilisateur (nom réel, email, téléphone, adresse IP) n'est stockée dans le système.
- **Anonymisation** : les contenus collectés depuis les plateformes communautaires sont nettoyés afin de supprimer les informations sensibles ou personnelles.
- **Finalité scientifique** : les données sont utilisées exclusivement dans un objectif académique, de recherche et d'analyse comportementale.

10.2 Respect des politiques robots.txt

Les opérations de scraping ont été réalisées dans le respect des politiques d'accès définies par les plateformes web analysées :

- limitation de la fréquence des requêtes (*rate limiting*),
- utilisation de délais entre les requêtes afin d'éviter toute surcharge des serveurs,
- collecte uniquement des données publiquement accessibles,
- absence de contournement des mécanismes de sécurité ou d'authentification.

Le système adopte ainsi une approche de collecte responsable conforme aux bonnes pratiques du Web Mining éthique.

10.3 Fiabilité et biais des données

Les données issues du web peuvent contenir :

- du bruit informationnel,
- des témoignages subjectifs,
- des doublons,
- ou des biais liés aux comportements des utilisateurs.

Afin de limiter ces problèmes, plusieurs mécanismes ont été intégrés :

- nettoyage et normalisation des données textuelles,
- déduplication des documents,
- comparaison multi-algorithmes pour réduire les faux positifs,
- pondération des sources grâce à l'algorithme HITS.

10.4 Usage responsable de l'Intelligence Artificielle

Les modèles de Machine Learning utilisés dans Bio-Sentry ont pour objectif d'assister l'analyse de pharmacovigilance et non de remplacer une expertise médicale humaine.

Les résultats produits par les algorithmes représentent des signaux statistiques ou comportementaux potentiels et ne constituent pas une validation clinique officielle. Toute interprétation médicale doit être confirmée par des spécialistes de santé ou des autorités compétentes.

10.5 Limites éthiques du système

Malgré les mécanismes de filtrage et de validation mis en place, certaines limites demeurent :

- présence possible de faux signaux de pharmacovigilance,
- qualité variable des témoignages utilisateurs,
- données incomplètes ou imprécises,
- biais de représentation des communautés en ligne.

Ces limites soulignent l'importance d'utiliser Bio-Sentry comme un outil d'aide à la surveillance épidémiologique et non comme un système de diagnostic médical autonome.

11 Recommandations pour les professionnels de santé

Les résultats obtenus dans le cadre du projet Bio-Sentry montrent l'intérêt des approches de Web Mining et d'apprentissage automatique pour renforcer les systèmes de pharmacovigilance traditionnels. Plusieurs recommandations peuvent ainsi être formulées à destination des professionnels de santé et des acteurs du secteur médical.

11.1 Renforcement de la veille pharmacovigilante

Les signaux détectés automatiquement par les algorithmes d'anomalie peuvent être utilisés comme mécanisme d'alerte précoce afin d'identifier rapidement des effets secondaires émergents avant leur validation officielle. Les professionnels de santé pourraient ainsi intégrer ce type d'outil dans les processus de surveillance clinique continue.

11.2 Priorisation des signaux critiques

Le système de consensus mis en place entre plusieurs algorithmes permet de hiérarchiser les niveaux d'alerte. Les signaux détectés simultanément par plusieurs modèles doivent être considérés comme prioritaires pour une analyse médicale approfondie.

11.3 Surveillance des tendances temporelles

L'analyse temporelle des données permet d'identifier des pics inhabituels d'effets secondaires associés à certains médicaments. Les autorités sanitaires peuvent exploiter ces tendances pour anticiper des risques émergents et adapter les politiques de surveillance.

11.4 Exploitation des données communautaires

Les plateformes communautaires telles que Reddit ou Drugs.com contiennent des signaux faibles souvent absents des bases officielles. Bien que ces données nécessitent une validation médicale, leur exploitation peut améliorer la réactivité des systèmes de pharmacovigilance.

11.5 Amélioration continue des modèles IA

Les modèles utilisés doivent être régulièrement réentraînés afin d'intégrer les nouvelles données médicales et d'améliorer leur capacité de généralisation. Une mise à jour continue des pipelines NLP et des modèles de clustering est essentielle pour maintenir la qualité des prédictions.

11.6 Collaboration entre experts médicaux et data scientists

L'interprétation des anomalies détectées nécessite une collaboration étroite entre professionnels de santé, pharmacologues et spécialistes en intelligence artificielle. Les modèles automatiques doivent être considérés comme des outils d'assistance à la décision et non comme des systèmes de diagnostic autonomes.

11.7 Perspectives futures

À long terme, Bio-Sentry pourrait être étendu vers :

- l'intégration de données hospitalières en temps réel,
- l'analyse multilingue des publications médicales et réseaux sociaux,
- la détection prédictive de crises sanitaires,
- ainsi que la mise en place de tableaux de bord décisionnels pour les autorités de santé.

Conclusion

Le projet Bio-Sentry a permis de développer une plateforme intelligente de pharmacovigilance et de veille épidémiologique basée sur les techniques de Web Mining, de Big Data et d'Intelligence Artificielle. En exploitant des données massives issues de sources médicales officielles, scientifiques et communautaires, le système vise à détecter précocement des signaux d'effets secondaires médicamenteux potentiellement émergents.

Les travaux réalisés ont permis de couvrir les trois axes fondamentaux du Web Mining : l'extraction sémantique des données biomédicales (Web Content Mining), l'analyse de la fiabilité des sources via le graphe de citations et l'algorithme HITS (Web Structure Mining), ainsi que l'analyse comportementale et temporelle des données à travers plusieurs approches de détection d'anomalies et de clustering (Web Usage Mining).

Dans le cadre de l'Axe 3, plusieurs algorithmes non supervisés ont été étudiés et comparés, notamment LOF, Isolation Forest, Z-Score Rolling, K-Means, Agglomerative Clustering et HDBSCAN. Les résultats obtenus montrent que ces approches sont capables d'identifier automatiquement des comportements atypiques, des regroupements significatifs ainsi que des signaux faibles de pharmacovigilance.

Le projet met également en évidence l'importance de la qualité des données, de la normalisation des sources hétérogènes et du respect des aspects éthiques et réglementaires liés à l'exploitation des données médicales issues du web.

Enfin, Bio-Sentry démontre le potentiel des approches de Web Mining et d'apprentissage automatique pour renforcer les systèmes traditionnels de surveillance sanitaire. À long terme, ce type de solution pourrait contribuer à améliorer la réactivité des systèmes de santé et à assister les professionnels dans l'identification précoce des risques médicamenteux et des phénomènes épidémiologiques émergents.